

STATISTIQUE 2

Mi-parcours du 20 mars 2026, Durée 1h30
Sans documents ni calculatrice, Justifier avec soin les réponses données

Exercice 1 On veut comparer la proportion p de naissances masculines à celle des naissances féminines grâce à un échantillon de $n = 900$ naissances. Dans notre échantillon on a 510 naissances masculines.

Données numériques: Si S suit une loi binomiale: $\text{Bin}(900; 0.5)$, alors $P(S \leq 474) = 0,9488271$, $P(S \leq 475) = 0,9554625$ et $P(S \leq 510) = 0,9999732$.

1. On veut tester les hypothèses:

$$H_0 : p = 0,5 \quad \text{vs.} \quad H_1 : p = 0,7$$

au niveau $\alpha = 0,05$.

- a) Modéliser le problème en définissant les variables aléatoires $X_1, \dots, X_n$, le modèle statistique et la vraisemblance de l'échantillon.
- b) Donner le test de Neyman-Pearson pour ce problème. Énoncer le résultat utilisé.
- c) Donner la p-value de ce test et prendre une décision à partir de cette valeur.
- d) Est-ce que le modèle statistique est à rapport de vraisemblance monotone?

2. On teste maintenant:

$$H_0 : p = 0,5 \quad \text{vs.} \quad H_1 : p > 0,5.$$

- a) Existe-t-il un test UPP au seuil $\alpha = 0,05$?

Corrigé: 1. a) On note X_i qui vaut 0 ou 1 si la naissance du i -ème individu est féminine ou masculine, respectivement. La loi de chaque X_i est de Bernoulli de paramètre p , dans le modèle $\{B(p), p \in [0, 1]\}$, et l'échantillon a une loi produit de n telles lois indépendantes. La vraisemblance de l'échantillon est:

$$L(\mathcal{E}_n, p) = \prod_{i=1}^n p^{X_i} (1-p)^{1-X_i} = p^{\sum_{i=1}^n X_i} (1-p)^{n - \sum_{i=1}^n X_i}.$$

- b) On note $R_n = \frac{L(\mathcal{E}_n, p_1)}{L(\mathcal{E}_n, p_0)}$. D'après le Lemme de Neyman-Pearson (l'énoncer!), si R_n a une loi continue, le test suivant est optimal

$$\phi = \mathbf{1}(R_n > c_\alpha),$$

où $c_\alpha > 0$ est le plus petit c tel que $P_{p_0}(R_n > c) \leq \alpha$. Si $P_{p_0}(R_n > c) < \alpha$ alors le test randomisé suivant est optimal:

$$\tilde{\phi} = \begin{cases} 1 & \text{si } R_n > c_\alpha \\ 0 & \text{si } R_n < c_\alpha \\ U & \text{si } R_n = c_\alpha \end{cases}$$

où U suit une loi de Bernoulli de paramètre γ tel que

$$P_{p_0}(R_n > c_\alpha) + \gamma P_{p_0}(R_n = c_\alpha) = \alpha.$$

c) On peut aussi écrire ϕ en utilisant $S = \sum_i X_i$: $\phi = \mathbf{1}(S > u_\alpha)$. La p-value est donc

$P_{p_0}(S > s) = P(\text{Bin}(n, p_0) > s) = 1 - 0,9999732 = 0,0000268$. Cette valeur est tellement petite que l'on peut rejeter H_0 .

d) Oui, on a pour $p_0 < p_1$:

$$R_n = \frac{p_1^S (1 - p_1)^{n-S}}{p_0^S (1 - p_0)^{n-S}} = \left(\frac{p_1(1 - p_0)}{(1 - p_1)p_0} \right)^S \cdot \left(\frac{1 - p_1}{1 - p_0} \right)^n$$

Donc R_n est croissant en S et le modèle est à rapport de vraisemblance monotone.

2. a) On utilise la monotonie de R_n en S et on obtient, d'après résultat du cours le test UPP:

$$\phi = \begin{cases} 1 & , S > 475 \\ 0 & , S < 475 \\ U & , S = 475 \end{cases}$$

avec U de loi de Bernoulli de paramètre γ tq

$$(1 - 0,9554625) + \gamma(0,9554625 - 0,9488271) = 0.05.$$

Exercice 2 Soit $\theta > 1$ un paramètre fixé et soient $X_1, \dots, X_n$ des variables aléatoires indépendantes ayant la même loi, de densité:

$$f(x, \theta) = \frac{\theta - 1}{x^\theta} \mathbf{1}_{[1, +\infty[}(x).$$

On pourra utiliser $\int_0^\infty v \exp(-v) dv = 1$ et $\int_0^\infty v^2 \exp(-v) dv = 2$.

1. Montrer qu'il existe deux constantes a et $b > 0$ telles que la suite

$$\frac{1}{b\sqrt{n}} \sum_{k=1}^n (\ln(X_k) - a)$$

converge en loi vers une variable Z de loi Gaussienne standard.

2. On veut faire le test $H_0 : \theta = 2$ contre l'alternative $H_1 : \theta = 3$. Quelle est la forme des tests de Neyman-Pearson? Que peut-on dire de la puissance asymptotique de ce test?

3. En déduire un test de niveau asymptotique $\alpha = 0,05$. Est-il asymptotiquement sans biais?

Rappel: si Z suit une loi gaussienne standard: $P(Z \leq 1,645) = 0,95$ et $P(Z \leq 1,96) = 0,975$.

Corrigé: 1. Par le TCL, on calcule $a = E[\ln(X)] = 1/(\theta-1)$ et $b^2 = \text{Var}(\ln(X)) = 1/(\theta-1)^2$.
 2. Pour $\theta = 2$, la région critique du test de Neyman-Pearson est de la forme

$$\frac{1}{\sqrt{n}} \sum_i (\ln(X_i) - 1) < -c_\alpha.$$

On calcule la puissance sous H_1 donc pour $\theta = 3$. On a $1/(\theta - 1) = 1/2$, donc $2/\sqrt{n} \cdot \sum_i (\ln(X_i) - 1/2)$ qui est asymptotiquement normale sous H_1 . Ainsi,

$$\begin{aligned} P_{\theta=3}(\frac{1}{\sqrt{n}} \sum_i (\ln(X_i) - 1) < -c_\alpha) &= P_{\theta=3}(\frac{1}{\sqrt{n}} \sum_i (\ln(X_i) - \frac{1}{2}) < -c_\alpha + \frac{\sqrt{n}}{2}) \\ &= P_{\theta=3}(\frac{2}{\sqrt{n}} \sum_i (\ln(X_i) - \frac{1}{2}) < -2c_\alpha + \sqrt{n}) \end{aligned}$$

et on montre qu'elle converge vers 1 avec n .

3. Le test asymptotique de niveau α est $\phi = \mathbf{1}(\frac{1}{\sqrt{n}} \sum_i (\ln(X_i) - 1) < -z_\alpha)$ avec $z_\alpha = 1,645$. Ici le quantile est calculé avec la loi Gaussienne asymptotique au lieu de la loi exacte de la question précédente.

Exercice 3 On observe un échantillon $X_1, \dots, X_n$ de variables aléatoires i.i.d. de loi Gaussienne inverse $N^-(\lambda, \mu)$ de densité de probabilité:

$$f(x; \lambda, \mu) = \sqrt{\frac{\lambda}{2\pi}} x^{-3/2} \exp\left(-\frac{\lambda}{2\mu} \left(\frac{x}{\mu} - 2 + \frac{\mu}{x}\right)\right) \mathbf{1}_{x>0}.$$

1. Déterminer les estimateurs de maximum de vraisemblance $(\hat{\lambda}_n, \hat{\mu}_n)$ de (λ, μ) .
2. L'information de Fisher de (λ, μ) dans ce modèle est

$$I(\lambda, \mu) = \begin{pmatrix} \frac{1}{2\lambda^2} & 0 \\ 0 & \frac{\lambda}{\mu^3} \end{pmatrix}$$

Donner le comportement asymptotique en loi de $(\hat{\lambda}_n, \hat{\mu}_n)$.

3. En déduire la forme du test de Wald pour tester $H_0 : \lambda = 2, \mu = 3$ au niveau asymptotique α .

Corrigé: 1. On passe à la log vraisemblance et on dérive par rapport à μ et on trouve $\hat{\mu}_n = \bar{X}_n$. On dérive en λ et on trouve

$$\hat{\lambda}_n = \frac{1}{\frac{1}{n} \sum_i \frac{1}{X_i} - \frac{1}{\bar{X}_n}}.$$

2. Par le TCL multivarié, on a

$$\sqrt{n}I(\lambda, \mu)^{1/2}((\hat{\lambda}_n, \hat{\mu}_n) - (\lambda, \mu)) \rightarrow N_2(O, I),$$

où la convergence est en loi.

3. Le test de Wald utilise la norme 2 du vecteur:

$$W_n(\lambda, \mu) := \|\sqrt{n}I(\lambda, \mu)^{1/2}((\hat{\lambda}_n, \hat{\mu}_n) - (\lambda, \mu))\|_2^2 = n\left(\frac{(\hat{\lambda}_n - \lambda)^2}{2\lambda^2} + \frac{\lambda(\hat{\mu}_n - \mu)^2}{\mu^3}\right)$$

qui converge vers un χ_2^2 à 2 degrés de libertés.

On peut utiliser $I(\hat{\lambda}_n, \hat{\mu}_n)$ au lieu de $I(\lambda, \mu)$.

La forme du test de Wald est $\{W_n(2, 3) > q_{1-\alpha}(\chi_2^2)\}$.